P2 阶段结果汇报

2026-10-22 | PI 阶段审查 | P3 与集中测试关闭

结论：P2 工程验收通过。48/48 个候选各完成 15 个完整 epoch，共 720 轮、39,935,160 个训练样本和 312,480 次 optimizer 更新。16 个配置的 LR 已按原规则冻结；未发现 OOM 或数值失败。

实际总成本 22.1117 / 30 GPU-hours，含全部验收、失败前缀、恢复、重跑和退出。项目及环境 44.18 GiB / 60 GiB，仍有至少 5 GiB 退出余量。

验证集表现概览

数据集 / 骨干	Scratch	Full FT	LP	Adapter
CIFAR-100 / R50	66.07	83.99	74.01	82.65
CIFAR-100 / ViT	39.75	92.14	87.31	92.72
SVHN / R50	95.37	94.97	68.41	95.03
SVHN / ViT	83.52	96.46	63.39	96.31

表内数值是各配置所选 LR 的第 13–15 轮验证 Top-1 均值（%），仅 seed=123。各格独立调参，不能当作测试成绩或五种子正式方法结论。

CIFAR-100：R50 Full FT 为 83.99%，Adapter 为 82.65%；ViT Adapter 为 92.72%，Full FT 为 92.14%。这些是在当前验证集和预算窗口内的描述性差异。

SVHN：R50 Scratch、Adapter、Full FT 分别为 95.37%、95.03%、94.97%；ViT Full FT 与 Adapter 分别为 96.46%、96.31%。LP 验证均值低于可适配主干的方法，冻结特征在这一设置下受限。

阶段结论：已具备将所选 LR 传入 P3 草案的工程条件。泛化、稳定性、显著性和方法优劣仍需原定五种子正式实验及封存后的集中测试；本轮未启动这些工作。

选参结果与解释边界

16 个配置；全部三档 LR 均保留

严格使用第 13、14、15 轮验证正确数总和比较；三轮验证样本数相同，等价于 Top-1 均值。精确并列时选择数值更小的 LR。表中 Full FT 列出主干 LR，分类头 LR 为其 10 倍。

数据集 / 骨干	方法	所选 LR	验证均值 (%)	网格位置
CIFAR-100 / R50	Scratch	0.003	66.0667	高边界
CIFAR-100 / R50	Full FT	0.0001	83.9933	高边界
CIFAR-100 / R50	LP	0.003	74.0133	中间
CIFAR-100 / R50	Adapter	0.0001	82.6533	低边界
CIFAR-100 / ViT	Scratch	0.0003	39.7533	低边界
CIFAR-100 / ViT	Full FT	1e-05	92.1400	低边界
CIFAR-100 / ViT	LP	0.001	87.3067	低边界
CIFAR-100 / ViT	Adapter	0.0001	92.7200	低边界
SVHN / R50	Scratch	0.001	95.3726	中间
SVHN / R50	Full FT	0.0001	94.9722	高边界
SVHN / R50	LP	0.003	68.4139	中间
SVHN / R50	Adapter	0.001	95.0314	高边界
SVHN / ViT	Scratch	0.0003	83.5153	低边界
SVHN / ViT	Full FT	3e-05	96.4646	中间
SVHN / ViT	LP	0.001	63.3861	低边界
SVHN / ViT	Adapter	0.0001	96.3054	低边界

12/16 个所选 LR 位于预注册网格边界：低边界 8 个，高边界 4 个，中间 4 个。因此本轮证明的是三档内的选择，不证明 LR 全局或局部最优。没有据此扩展网格或追加候选。

高 LR 的 ViT Scratch 产生很低的验证平台：CIFAR-100 的 3e-3 档均值 5.65%，SVHN 的 3e-3 档均值 18.92%；所有记录数值仍有限。低准确率与 NaN 是不同事件，不能把本轮零 NaN 写成历史 NaN 根因已解决。

部分配置训练损失继续下降而验证损失回升。该现象支持在 P3 检查泛化和时间预算轨迹，不能据单条曲线证明过拟合机制或修改原选参标准。

效率与参数开销

均采用各配置所选 LR 的真实 P2 测量

完整轮时间取第 2–15 轮 train + validation + checkpoint 完整事务耗时中位数，含实际并发环境。GPU 内存为 torch 记录的 allocated 峰值；它与设备总占用、reserved 峰值不同。

数据集 / 骨干	方法	训练参数 / 百万	完整轮 / 秒	GPU 分配峰值 / GiB
CIFAR-100 / R50	Scratch	23.713	78.53	1.822
CIFAR-100 / R50	Full FT	23.713	79.85	1.822
CIFAR-100 / R50	LP	0.205	30.54	0.896
CIFAR-100 / R50	Adapter	10.302	83.34	2.237
CIFAR-100 / ViT	Scratch	85.876	142.35	3.599
CIFAR-100 / ViT	Full FT	85.876	139.40	3.599
CIFAR-100 / ViT	LP	0.077	50.09	1.034
CIFAR-100 / ViT	Adapter	3.627	110.06	2.043
SVHN / R50	Scratch	23.529	115.01	1.819
SVHN / R50	Full FT	23.529	114.16	1.819
SVHN / R50	LP	0.020	43.60	0.893
SVHN / R50	Adapter	10.118	119.51	2.234
SVHN / ViT	Scratch	85.806	203.42	3.598
SVHN / ViT	Full FT	85.806	202.71	3.598
SVHN / ViT	LP	0.008	72.49	1.033
SVHN / ViT	Adapter	3.558	159.13	2.042

ViT Adapter 的训练参数约 3.56–3.63 百万，约为对应 Full FT 的 4.1–4.2%；R50 Adapter 约 10.12–10.30 百万，约为对应 Full FT 的 43%。两种 Adapter 的相对开销不能混称为同一参数比例。

R50 Adapter 的 allocated 峰值高于 Full FT，完整轮也略慢；减少可训练参数并未自动减少激活图或插入模块的代价。ViT Adapter 则在本轮同时减少训练参数、轮时间和 allocated 峰值。

LP 的完整轮耗时大约是对应 Full FT 的 36%–39%，但验证表现有明显代价。效率比较使用完整轮中位数，避免把某个候选额外经历的技术中断成本当成方法固有耗时。

工程验收、事故与可追溯性

56 个 attempt 全结算；无 GPU 任务留在运行状态

独立交付复核逐文件验证 2,133 份原始证据，重新核对所有 epoch 事务链、科学配置 hash、配对 sampler、分类头初始化、样本数、尾窗口和 optimizer 更新数；再精确重算 16 组 LR 选择。

真实执行身份由 17 个 6c0a215 完成候选与 31 个 d66193b 完成/恢复候选组成。科学实现基线保持 6c0a215；新运维源码、实际 commit 和验收独立绑定，原 17 个候选 summary/epochs SHA 保持不变。

初版 092bcfb 发现终轮摘要恢复和 workers 终止分类问题，两个未完成前缀归档后重新初始化。随后存储统计在原子重命名时发生 FileNotFoundError，17 个完成项保留、两个中断项从第 6/3 轮提交恢复。两次事故均保留现场及费用，没有为改善成绩重跑。

最终 18 项 CPU 检查通过，含全部事务边界、身份不匹配、精确选参、共享预算、进程死亡和存储竞态。真实 GPU 恢复覆盖两个正式中断前缀及 R50/ViT 合成检查：恢复状态一致、重复继续更新逐位一致、错误 LR 被拒绝。

资源 / 证据	最终实测
P2 全部实际 GPU-hours	22.111704 / 30
GPU 验收占用（包含在总数中）	0.023809 GPU-hours
项目 + 环境逻辑占用	44.176 GiB / 60 GiB
P1 checkpoint 留存及重核	40 份
P2 checkpoint 留存及重核	128 份：常规 120 + 技术归档 8
模型 checkpoint 下载	0 份；全部留服务器

数据边界：CIFAR-100 既有完整性记录发现 26 个重复组，其中 14 个跨已分配 split；SVHN 有 1 个重复组但无跨已分配 split 重复。沿用冻结 split，不在调参过程中改数据。相关局限仍需保留。

所有验证结果来自单个调参种子；每个数据集使用固定的验证划分，未估计置信区间或做显著性检验。R50 与 ViT 使用不同预训练来源（IN1K / IN21K），跨骨干差异不能单独归因为模型架构。

P3 资源提案与进入条件

草案待 PI 审核；本次没有 P3 或测试执行许可

原定 16 配置 × 五种子（17、42、2026、3407、65537）= 80 个正式 run，全部从原始初始化训练 50 轮；所选 LR 和 selected_hparams SHA 已解析，不续训 P2。

项目	GPU-hours 提案
80 个正式 run 基础训练	121.333
最多 240 个额外 prefix 保存	0.167
最多 400 个评价角色	1.465
诊断预留 + 推理基准预留	2.000 + 0.500
上述合计并加 25%	156.831
建议新阶段独立硬上限（待批准）	160.000

保存当前全部 P1/P2、P3 best/last/delta 与最多三份额外 prefix，再加 25% 的项目及环境存储情景为 182.80 GiB，建议确认至少 200 GiB。当前 60 GiB 不覆盖该提案；此情景也超过旧 100 GiB 规划线，须 PI 显式批准新的额度或保留政策。

算力外推采用所选 P2 候选完整轮时间，已包含实际并发，不重复乘慢化因子。prefix 保存按完整事务费用保守计；最多 400 个评价角色用验证时序和样本数缩放，尚无测试推理。160 GPU-hours 是建议硬上限，须经下一次授权。

组	0.25B / 秒	0.5B / 秒	B / 秒
CIFAR-100 / R50	383.7	767.5	1535.0
CIFAR-100 / ViT	628.5	1257.0	2514.1
SVHN / R50	547.3	1094.6	2189.1
SVHN / ViT	908.9	1817.7	3635.4

时间切片建议 B 为每个 dataset/backbone 组四方法 timing-only 的 50 轮估算最小值，取 0.25B、0.5B、B；这些数值尚未冻结，不能按准确率重新选 B。

进入 P3 前：批准独立 GPU/存储额度并冻结 B；验收 80-run 入口、不可变 prefix、累计提交时间和 P3 seal；建立唯一 evaluation_id 与按 run+checkpoint SHA 复用预测；在构造 TestData 前严格校验封存、状态、角色和身份。五种子配对分析、Holm 校正及非劣效界限沿用原合同。

P2 工程交付后停止。P3、集中测试和测试预测保持关闭，等待下一次阶段审核。